

Llama-3.2-1B | Quantized layer 4 | float16 $\rightarrow$ int4

