

Llama-3.2-1B | Quantized layer 1 | float16  $\rightarrow$  int4

