

Llama-3.2-1B | Quantized layer 1 | float16 $\rightarrow$ int4

