

Llama-3.2-1B | Quantized layer 0 | float32  $\rightarrow$  int4

