

Llama-3.2-3B | Quantized layer 5 | float16  $\rightarrow$  int4

