

Llama-3.2-3B | Quantized layer 16 | float16  $\rightarrow$  int4

