

Llama-3.2-3B | Quantized layer 25 | float16  $\rightarrow$  int4

