

Llama-3.2-3B | Quantized layer 1 | float32  $\rightarrow$  int4

