

Llama-3.2-3B | Quantized layer 4 | float32  $\rightarrow$  int4

