

Llama-3.2-3B | Quantized layer 16 | float32 $\rightarrow$ int4

